

DMSA - FORDCITO: Sistema Agéntico de Posventa Ford Territory

Sección 1. Portada y resumen ejecutivo

FORDCITO atiende por Telegram, en texto y voz, las consultas de posventa de la Ford Territory (manual, garantía y turnos de service), responde solo con la documentación oficial y exige aprobación humana antes de reservar un turno en la agenda del taller.

Dato	Detalle
Proyecto	FORDCITO - Asistente IA de Posventa Ford Territory
Autor	Facundo Ezequiel Cabanilla
Cohorte	2026 – Carrera de IA y Automatización Agéntica, Coderhouse
Estado	Prototipo funcional validado en entorno de pruebas (n8n, capa freemium)
Repositorio de workflows	github.com/facucabanilla/AI-Automation-Avanzado-Trabajo-final
Video (opcional)	Ver video en Loom

Problema de negocio

Un concesionario promedio recibe 1.200 consultas de posventa por mes y cada una insume unos 5 minutos de un administrativo: 100 horas-hombre mensuales en tareas repetitivas (dato de partida estimado, a validar en la Fase 0 de Modo Sombra). Esa carga tiene dos costos de negocio:

- **Capacidad:** el equipo atiende dudas básicas en lugar de vender repuestos y servicios de mayor margen.
- **Riesgo:** si el cliente no recibe una respuesta inmediata, busca en foros o buscadores no oficiales; la información errónea puede provocar mal uso del vehículo o la pérdida de la garantía oficial.

Qué resuelve la solución, en términos de negocio

Capacidad	Beneficio
Atención 24/7 por Telegram, con texto y notas de voz	Respuesta inmediata; el administrativo deja de ser el cuello de botella
Responde solo con los manuales oficiales cargados y dice "No sé" cuando no hay respaldo	Menor riesgo de información inventada o inexacta
Auditor automático de calidad (AI-as-a-Judge) sobre las respuestas del manual técnico	Control de calidad antes de que el dato llegue al cliente
Propuesta de 3 turnos libres; el cliente elige y un humano confirma en Slack	Ningún turno entra al calendario del taller sin control humano
Registro con identificador único (traceld) en Google Sheets	Auditoría y reconstrucción de cada conversación

Resultados clave (detalle en la Sección 4)

Indicador	Operación manual	Con FORDCITO
Horas humanas por mes (1.200 consultas)	100 h	19 h (81 h liberadas, 81%)
Costo operativo mensual	USD 500	USD 147
Ahorro neto operativo	-	USD 353/mes · USD 4.236/año
Costo por consulta	USD 0,42	USD 0,12
Costo de IA (tokens)	-	menos de USD 1/mes

Estas cifras son proyecciones con supuestos explícitos (Sección 4); la Fase 0 del roadmap las valida con datos reales del concesionario.

Alcance de la supervisión automática

El supervisor AI-as-a-Judge opera hoy sobre la rama de consultas del manual del usuario, la de mayor riesgo de alucinación técnica y de seguridad. Garantía y Mantenimiento se rigen por restricciones de prompt, la regla "No sé" y un tope de longitud de respuesta; los turnos pasan por aprobación humana obligatoria. Extender el Judge a Garantía y Mantenimiento es el primer ítem del roadmap (Anexo B).

Sección 2. Arquitectura en n8n

El sistema son cuatro workflows de negocio independientes (un Manager que recibe, clasifica y registra, y tres Workers especializados que resuelven) más un quinto workflow de alertas de error; cada petición viaja con un traceld único que permite reconstruirla de punta a punta.

2.1 Mapa de workflows (patrón Manager-Worker)


Workflow	Rol	Qué hace	Resultado para el negocio
Asistente Ford (Fordcito) - MANAGER	Manager	Recibe el mensaje de Telegram (texto o voz), transcribe los audios con Gemini, asigna el traceld, clasifica la intención (Saludo, Manual, Garantía, Mantenimiento/Turnos), delega y registra en Google Sheets	Un único punto de entrada y de auditoría
Asistente Ford (Fordcito) - Worker MANUAL	Worker 1	Consulta la base vectorial del manual del usuario; el Juez evalúa la respuesta; si no alcanza la nota, se autocorriga (tope de 2 reintentos) y luego deriva a un humano en Slack	Respuestas técnicas verificadas antes de llegar al cliente

Workflow	Rol	Qué hace	Resultado para el negocio
Asistente Ford (Fordcito) - Garantía	Worker 2	Consulta la base vectorial de garantía; respuesta de hasta 200 caracteres; si no hay respaldo documental responde "No sé"	Plazos y coberturas consistentes con la documentación oficial
Asistente Ford (Fordcito) - Turnos y mantenimiento	Worker 3	Distingue consulta de mantenimiento (RAG, hasta 500 caracteres) de pedido de turno; para turnos lee la agenda, propone 3 horarios de 2 horas, el cliente elige y un humano aprueba en Slack antes de crear el evento	Agenda sin turnos no autorizados
Asistente Ford (Fordcito) - Alerta de errores	Soporte	Se activa solo cuando falla cualquier otro workflow y avisa por Slack con el nombre del workflow, el nodo, el mensaje de error y el enlace a la ejecución	Fallas visibles en minutos, sin revisar registros a mano

2.2 Flujo de datos de punta a punta

El mensaje entra al Manager, se clasifica una sola vez y se delega al Worker correspondiente; la respuesta vuelve al cliente por el mismo canal y todo queda registrado con el mismo traceId.

El Manager clasifica y solo la rama Manual pasa por el Juez automático



Contorno destacado: rama con supervisor automático. Línea punteada: derivación a revisión humana.

arquitectura Manager-Worker · 4 workflows, 1 supervisor

- 1. Entrada y respuesta inmediata.** El disparador de Telegram es un webhook: recibe el mensaje, confirma recepción al instante y el procesamiento corre en segundo plano.
- 2. Voz.** Si el mensaje es una nota de voz, se descarga y se transcribe con Gemini; si la transcripción llega vacía, el sistema pide al cliente que reenvíe el audio o escriba.
- 3. Identificación.** Se asigna el traceld (el identificador de ejecución de n8n) y se marca si la respuesta debe ser TEXTO o AUDIO según cómo escribió el cliente.
- 4. Clasificación.** Un agente liviano devuelve una sola palabra: SALUDO, MANUAL, GARANTIA o MANTENIMIENTO_TURNOS.
- 5. Delegación.** El Manager ejecuta el Worker elegido como sub-workflow independiente y espera su resultado.
- 6. Respuesta.** El Worker responde por Telegram en texto, o en audio (ElevenLabs) si el cliente habló.
- 7. Registro.** El Manager guarda fecha, traceld, chatId, consulta y respuesta en Google Sheets; el Worker Manual agrega su propio registro con la nota del Juez.

Registro de consultas por voz: cuando el cliente envía un audio, cada Worker responde en el formato original (voz o texto). Para el registro final, el Manager vuelve a transcribir el audio original y guarda el texto de la consulta junto con la respuesta, de modo que cada interacción queda registrada en texto.

2.3 Contrato entre Manager y Workers (acople contextual)

Cada Worker recibe exactamente los mismos cuatro datos, lo que permite probarlo, versionarlo y reemplazarlo sin tocar a los demás.

Parámetro	Contenido	Para qué se usa
traceID	ID de ejecución del Manager	Correlación entre workflows y registros
Consulta	Texto escrito o transcripción del audio	Pregunta que debe resolver el Worker
chatID	Identificador del chat de Telegram	Destino de la respuesta y trazabilidad del cliente
formato_respuesta	TEXTO o AUDIO	Define si se responde con texto o con voz

2.4 Memoria y base de conocimiento

- **Memoria persistente de largo plazo:** base vectorial en Supabase (pgvector) con dos tablas: el manual del usuario y el documento de garantía y mantenimiento. Los textos se vectorizan con Cohere (embed-english-v3.0) y se consultan por similitud.
- **Memoria operativa y de auditoría:** Google Sheets conserva el historial de consultas y respuestas por traceId y chatId.
- **Límite actual:** cada consulta se resuelve de forma independiente; la memoria conversacional multi-turno por chatId está en el roadmap (Anexo B).

2.5 Resiliencia y control de fallas

Capacidad	Estado	Cómo funciona o plan de cierre
Respuesta inmediata y proceso en segundo plano	Implementado	Webhook de Telegram con ejecución asíncrona

Capacidad	Estado	Cómo funciona o plan de cierre
Audio ilegible	Implementado	Pide reenviar el mensaje
Autocorrección de respuestas del manual	Implementado	Hasta 2 reintentos guiados por la crítica del Juez; luego derivación a humano
Aprobación humana de turnos	Implementado	Sin aprobación en Slack no se crea el evento en el calendario
Respuesta humana al cliente tras un rechazo	Implementado	La respuesta que escribe el operador en Slack se envía al cliente por Telegram
Alerta ante caída de APIs externas	Implementado	El workflow "Asistente Ford (Fordcito) - Alerta de errores" avisa por Slack con el workflow, el nodo, el mensaje de error y el enlace a la ejecución
Reintento automático de llamadas a APIs	Implementado	3 intentos con 2 s de espera en los nodos de lectura y consulta; no se aplica a los envíos que podrían duplicarse
Deduplicación de mensajes repetidos	Pendiente	Registrar el identificador del mensaje entrante y descartar repetidos

Sección 3. Reporte de auditoría y rúbricas

Cada respuesta del Worker Manual la evalúa un supervisor automático antes de llegar al cliente: con nota 4 o 5 se entrega, con nota 3 se corrige y con nota 2 o menos se detiene y pasa a una persona.

3.1 Cómo funciona el supervisor (AI-as-a-Judge)

- **Qué recibe:** la consulta del cliente, los fragmentos del manual recuperados de la base vectorial y la respuesta propuesta por el agente.

- **Qué entrega:** un JSON con tres campos fijos: `exactitud_factual` (1 a 5), `estado_veredicto` (ACEPTADO, CORREGIR o RECHAZADO) y `critica_justificacion`.
- **Umbral de aprobación:** `exactitud_factual` igual o mayor a 4. Por debajo, el sistema no entrega la respuesta de forma autónoma.
- **Por qué solo en el Manual:** es la rama con mayor riesgo técnico y de seguridad (presiones, testigos del tablero, especificaciones). Garantía y Mantenimiento tienen controles propios (respaldo documental obligatorio, regla "No sé" y tope de longitud) y la extensión del Juez figura en el roadmap.

3.2 Rúbrica y acción del sistema

Nota	Clasificación	Criterio	Acción del sistema
5	Excelente	Total precisión factual, basada exclusivamente en el contexto recuperado	ACEPTADO: se entrega al cliente y se registra
4	Bueno	Factualmente correcta, con leves imperfecciones de formato o tono	ACEPTADO: se entrega al cliente y se registra
3	Regular	Omite detalles menores o el tono no es óptimo, pero no inventa datos	CORREGIR: el agente reintenta con la crítica del Juez (hasta 2 veces)
2	Malo	Imprecisiones parciales o contradicciones leves con el contexto	RECHAZADO: se frena la respuesta y se alerta a una persona en Slack
1	Inaceptable	Alucinación grave, información falsa o no responde la consulta	RECHAZADO: se frena la respuesta y se alerta a una persona en Slack

Si tras los 2 reintentos la nota sigue siendo 3, el caso también pasa a revisión humana. El mensaje de Slack incluye la respuesta propuesta, la nota y el motivo; el operador responde en el mismo mensaje y esa respuesta se envía automáticamente al cliente por Telegram. En consultas de varias partes, el Juez cuenta las partes detectadas y las correctas y cierra su crítica con ese conteo; la nota debe coincidir con él (todas las partes: 4 o 5; al menos la mitad: 3; menos de la mitad: 2 o menos).

3.3 Formato del registro

El supervisor devuelve este JSON plano, validado contra un esquema (Structured Output Parser):

```
{
  "exactitud_factual": 5,
  "estado_veredicto": "ACEPTADO",
  "critica_justificacion": "La respuesta es correcta."
}
```

Cada evaluación se guarda en Google Sheets con este objeto de trazabilidad:

```
{
  "traceId": "1145",
  "timestamp": "2026-09-14 12:41:36",
  "nodeName": "AI-as-a-Judge",
  "systemPromptSnapshot": "Asistente_Territory_v1.0",
  "chatId": "<id del chat de Telegram>",
  "consulta": "<pregunta del cliente>",
  "toolOutput": "<respuesta del agente>",
  "exactitud_factual": 5,
  "estado_veredicto": "ACEPTADO",
  "critica_justificacion": "<crítica del Juez>"
}
```

3.4 Tres evaluaciones reales

Ejemplo 1: respuesta aceptada (nota 5). Ejecución real del 07/10/2026 a las 15:44:26 (hora de Argentina), traceId 1663. Consulta del cliente: "¿Qué presión de neumáticos lleva?". Respuesta del agente: "La presión recomendada se encuentra en la etiqueta de inflado de neumáticos ubicada en el vehículo. También puede verificar las lecturas actuales en la pantalla de información."

```
{
  "exactitud_factual": 5,
  "estado_veredicto": "ACEPTADO",
  "critica_justificacion": "La respuesta del agente es totalmente precisa y se basa estrictamente en el contexto proporcionado. Indica correctamente que la presión recomendada se encuentra en la etiqueta de inflado del vehículo y que las lecturas actuales se pueden verificar en la pantalla de información, sin inventar valores numéricos que no figuran en la documentación recuperada."
}
```

Ejemplo 2: consulta de tres partes, una fuera de cobertura (ACEPTADO, nota 5).

Ejecución real del 07/10/2026 a las 16:30:04 (hora de Argentina), traceld 1684. Consulta del cliente: "¿Qué luces lleva? ¿Cuál es la capacidad del tanque de combustible? ¿Cuánto sale el seguro?". El agente buscó cada tema por separado, respondió las luces y el tanque (60 ± 2 litros) con datos del manual y aclaró que el precio del seguro no figura en la documentación. El Juez contó 3 partes detectadas y 3 correctas: informar que algo no figura es correcto cuando el contexto realmente no lo contiene.

```
{
  "exactitud_factual": 5,
  "estado_veredicto": "ACEPTADO",
  "critica_justificacion": "El usuario realizó 3 preguntas: 1) qué luces lleva, 2) cuál es la capacidad del tanque de combustible, y 3) cuánto sale el seguro. El agente respondió correctamente sobre las luces, sobre la capacidad del tanque y aclaró de forma adecuada que el precio del seguro no figura en la documentación disponible. Partes: 3 detectadas, 3 correctas."
}
```

Ejemplo 3: respuesta rechazada y derivada a una persona (nota 1). Caso de prueba del 07/10/2026 a las 15:55:07 (hora de Argentina), traceld 1672, con la base documental desconectada a propósito para simular una caída de la fuente de conocimiento. Consulta del cliente: "Que presión llevan los neumáticos?". El agente no produjo una respuesta válida, el Juez la rechazó, no se entregó nada al cliente y el caso se derivó a una persona en Slack.

```
{
  "exactitud_factual": 1,
  "estado_veredicto": "RECHAZADO",
  "critica_justificacion": "El agente ha fallado por completo en su tarea principal: en lugar de responder a la consulta del usuario sobre la presión de los neumáticos de la Ford Territory utilizando el manual, ha devuelto una instrucción técnica/sistema sobre cómo formatear la salida en JSON. No hay respuesta a la pregunta del usuario."
}
```

3.5 Métricas de precisión en pruebas

Set de pruebas: 10 ejecuciones reales de la rama Manual del 07/10/2026, enviadas por Telegram o relanzadas desde el editor de n8n (en tres de ellas el traceld se corrigió a mano en la planilla, porque el editor reutiliza el identificador de la ejecución original). Incluye consultas simples, consultas de tres partes, una parte fuera de cobertura y dos fallas inducidas a propósito (base documental desconectada y respuesta truncada). No incluye consultas por voz en esta tanda. Los casos se agrupan según la versión del sistema: Etapa 1, configuración inicial (4 casos); Etapa 2, descomposición de consultas y rúbrica por partes (2 casos); Etapa 3, configuración final con más resultados recuperados, sinónimos en el prompt y regla de consistencia del Juez (4 casos). Con 10 casos las cifras son indicativas, no estadísticas.

Métrica	Etapas				Total
	Etapas 1 (4)	Etapas 2 (2)	Etapas 3 (4)		(10)
Aprobadas en el primer intento (ACEPTADO)	3	1	3		7
Enviadas a autocorrección (CORREGIR)	0	1	0		1
Rechazadas y derivadas a una persona (RECHAZADO)	1	0	1		2
Nota promedio del Juez (1 a 5)	4,0	4,0	4,25		4,1
Coincidencia entre el Juez y el criterio humano	3 de 4	1 de 2	4 de 4		8 de 10
"No figura" erróneo (el manual sí tenía el dato)	1	1	0		2

Métrica	Etapa 1 (4)	Etapa 2 (2)	Etapa 3 (4)	Total (10)
Partes fuera de cobertura marcadas correctamente como "no figura"	0	0	2	2

Criterio humano: contraste de cada respuesta con el contenido del manual. Lectura: el Juez coincidió con el criterio humano en 8 de 10 casos (6 de 8 sin contar las dos fallas inducidas). Sus dos desaciertos fueron el mismo problema: el agente respondió que algo "no figura" cuando el manual sí lo contenía (presión de neumáticos y capacidad del tanque, recuperados correctamente en la Etapa 3), y como el Juez solo ve lo recuperado, no pudo detectarlo. Tras ajustar la recuperación, el prompt y la regla de consistencia, los 4 casos de la Etapa 3 coincidieron. Quedan sin medir el tiempo de respuesta y la ruta completa de autocorrección (CORREGIR con reintento): ambos se declaran en el Anexo B.

Sección 4. Justificación financiera

Con 1.200 consultas por mes, atender con FORDCITO cuesta USD 147 contra USD 500 de la operación manual: un ahorro neto operativo de USD 353 mensuales (70,6%), con 81 de las 100 horas humanas liberadas; el costo de la IA (tokens) es menos del 1% del total.

4.1 Supuestos del modelo

Parámetro	Valor	Fuente o estado
Consultas por mes (un concesionario)	1.200	Pre-entrega 1; a validar en Modo Sombra
Tiempo de atención manual	5 minutos por consulta (100 h/mes)	Pre-entrega 1; a validar

Parámetro	Valor	Fuente o estado
Costo hora de un administrativo	USD 5,00 (ARS 7.750), caso base	CCT 130/75, Administrativo A, octubre 2026: ARS 1.316.632 por mes con la suma no remunerativa de ARS 120.000 (Ámbito). Con divisor de 200 horas son ARS 6.583 por hora (USD 4,25); con cargas sociales y proporcionales se estima en USD 6 (estimación propia). Se usa USD 5 como caso base conservador.
Costo hora alternativo	USD 9,00 (ARS 13.950)	Pre-entrega Módulo 10; se usa en la sensibilidad
Tipo de cambio	ARS 1.550 por USD	Referencia de las pre-entregas
Distribución de consultas	70% informativas, 20% turnos, 10% diagnóstico presencial	Pre-entrega 1
Tokens por consulta	2.200 de entrada y 250 de salida	Supuesto: clasificador, agente con contexto RAG y Juez
Tarifa de referencia por millón de tokens	USD 0,15 entrada y USD 0,60 salida	Referencia de modelos económicos; el prototipo usa Gemini Flash-Lite en capa freemium. Validar con la tarifa vigente
Respuestas en audio	30% de las consultas (360 por mes), USD 0,004 cada una	Supuesto
Infraestructura en producción	USD 50 por mes (n8n en la nube y base vectorial)	Supuesto; USD 0 en el prototipo freemium

4.2 Costo mensual en tokens

Concepto	Volumen mensual	Costo (USD)
Tokens de entrada	2,64 millones	0,40
Tokens de salida	0,30 millones	0,18
Total de tokens		0,58
Prueba de estrés: tarifa 10 veces mayor		5,76
Síntesis de voz (360 audios)		1,44

La conclusión no depende de la tarifa exacta: aun multiplicada por diez, la IA cuesta menos de USD 6 por mes.

4.3 Horas humanas evitadas

Tarea humana restante	Volumen	Minutos por caso	Horas por mes
Revisión por muestreo de respuestas informativas (5% de 840)	42	3	2,1
Confirmación de turnos en Slack	240	2	8,0
Agenda de diagnóstico presencial	120	3	6,0
Casos que el Juez deriva a una persona (5% de 840)	42	4	2,8
Total con FORDCITO			18,9 (se usan 19)
Operación manual actual	1.200	5	100
Horas liberadas			81 (81%)

Los minutos y porcentajes de esta tabla son hipótesis de trabajo; la Fase 0 del roadmap las reemplaza con mediciones reales.

4.4 Comparativa mensual: operación manual contra FORDCITO

Concepto	Manual	Con FORDCITO
Mano de obra (USD 5 por hora)	USD 500,00 (100 h)	USD 95,00 (19 h de supervisión)
Tokens	–	USD 0,58
Síntesis de voz	–	USD 1,44
Infraestructura	–	USD 50,00
Total mensual	USD 500,00 (ARS 775.000)	USD 147,02 (ARS 227.881)
Costo por consulta	USD 0,42	USD 0,12
Ahorro neto mensual		USD 352,98 (ARS 547.119)
Ahorro neto anual		USD 4.235,76 (ARS 6.565.428)

A diferencia de un cálculo que solo mire el costo de las APIs, este total incluye la supervisión humana y la infraestructura.

4.5 Sensibilidad y lectura comercial

El resultado depende sobre todo del costo de la hora humana. La lectura comercial suma el servicio mensual del proveedor (USD 350, que ya incluye la infraestructura) y compara contra la operación manual; el pago único de configuración es de USD 1.500.

Escenario	Ahorro neto mensual operativo	Ahorro neto mensual con servicio de USD 350	Recupero de la configuración	Volumen de equilibrio
Hora a USD 5 (caso base)	USD 352,98	USD 52,98	unos 28 meses	cerca de 1.040 consultas por mes
Hora a USD 9	USD 676,98	USD 376,98	unos 4 meses	cerca de 580 consultas por mes

Lectura para el comité: la operación propia es rentable en ambos escenarios; el modelo comercial con servicio mensual es claramente rentable si la hora cuesta USD 9 y queda cerca del equilibrio si cuesta USD 5, donde el valor principal es la capacidad liberada (81 horas mensuales para vender repuestos y servicios) y la escala a más concesionarios.

4.6 Control de costos

- **Modelos económicos** (Gemini Flash-Lite) en el clasificador, los agentes y el Juez.
- **Respuestas cortas:** la instrucción es de hasta 200 caracteres en Manual y Garantía (350 si la consulta tiene varias partes) y 500 en Mantenimiento. Es una instrucción del prompt, no un control técnico (Anexo B).
- **Contexto acotado:** el Manual usa la recuperación estándar; Garantía y Mantenimiento recuperan 20 fragmentos porque el programa de mantenimiento está dividido en tablas que hay que cruzar.
- **Tope de 2 reintentos** del Juez, para evitar bucles que consuman tokens.
- **Límite de gasto mensual:** recomendado, no implementado en el prototipo, que usa capas gratuitas con sus propios topes. Para producción se propone un límite de USD 20 al mes para el proveedor de modelos y USD 10 para voz, con aviso al llegar al 80%. Son entre 3 y 7 veces el gasto esperado, así que cubren picos sin permitir un consumo descontrolado.

Anexo A. Gobernanza de datos y parámetros de conexión

Ningún prompt, workflow exportado ni texto de este documento contiene claves o tokens reales: n8n guarda los secretos cifrados en su gestor de credenciales y los JSON exportados solo referencian el nombre de cada credencial.

A.1 Credenciales necesarias (solo nombres, nunca valores)

Credencial en n8n	Servicio	Qué datos necesita	Uso
Telegram account	Telegram Bot API	Token del bot	Recibir mensajes y responder
Google Gemini(PaLM) Api account	Gemini API	Clave de API	Clasificador, agentes, Juez y transcripción de audio

Credencial en n8n	Servicio	Qué datos necesita	Uso
Cohere - Facundo	Cohere	Clave de API	Vectorización de consultas
Supabase - Manual Territory	Supabase	URL del proyecto y clave de servicio	Base vectorial
ElevenLabs account	ElevenLabs	Clave de API	Respuestas en audio
Slack account	Slack (OAuth2)	Permiso para enviar mensajes y esperar respuesta	Revisión humana y aprobación de turnos
Google Sheets account 2	Google Sheets (OAuth2)	Acceso a las hojas de registro	Auditoría
Google Calendar account	Google Calendar (OAuth2)	Lectura y creación de eventos	Disponibilidad y turnos

A.2 Estructuras de datos

Almacén	Estructura	Función
Supabase, tabla document_chunks	id (uuid), content (texto), metadata (JSON con las líneas del fragmento, no la página) y embedding (vector de 1024 dimensiones según el modelo de Cohere). Estructura verificada en Supabase el 07/10/2026	Manual del usuario; consulta con la función match_documents
Supabase, tabla document_garantia_chunks	Misma estructura	Garantía y programa de mantenimiento; consulta con la función match_document_garantia_chunks
Google Sheets, registro del Manager	Fecha y hora, traceID, chatID, Consulta, Respuesta	Historial de todas las consultas

Almacén	Estructura	Función
Google Sheets, registro del Juez	tracelD, timestamp, Query Usuario, toolOutput, Veredicto Juez, exactitud_factual, systemPromptSnapshot, Log_JSON	Evaluaciones del supervisor

A.3 Proveedores y privacidad

Proveedor	Datos que recibe	Condición
Google Gemini	Consultas de clientes y audios	En la capa gratuita, Google puede usar los datos para mejorar sus productos; el prototipo se prueba solo con consultas de ejemplo y, en producción, corresponde el plan de pago con términos de no uso para entrenamiento. Validar los términos vigentes
Cohere	Texto de la consulta	Las claves de prueba son de uso no productivo; en producción corresponde un plan productivo
ElevenLabs	Texto de la respuesta, sin datos personales	Validar el plan y sus términos
Supabase	Documentos oficiales y sus vectores	Cifrado en reposo y en tránsito, estándar del proveedor
Telegram, Slack, Google	chatId, mensajes, turnos	Acceso con tokens u OAuth2 y permisos mínimos; cifrado en tránsito (HTTPS/TLS)

Políticas propuestas: el sistema guarda solo el chatId y el texto de la consulta; los registros se conservan 90 días; cuando se incorporen nombre y patente en el agendamiento, aplica la Ley 25.326 de Protección de Datos Personales (consentimiento y finalidad). Este documento no declara contratos de retención cero de datos, porque no están contratados.

A.4 Riesgos y controles

Riesgo	Control	Estado
Respuestas inventadas	Consulta obligatoria a la base documental, regla "No sé" y Juez en la rama Manual	Implementado en Manual; parcial en el resto
Instrucciones maliciosas en el mensaje del cliente	El agente responde solo con la base documental y el Juez evalúa contra ella	Parcial
Fuga de credenciales	Secretos en el gestor de credenciales, ninguno en prompts ni textos	Implementado
Gasto descontrolado	Respuestas cortas, tope de 2 reintentos y límite de gasto por proveedor	Parcial (límite por configurar)
Caída de una API externa	Alerta por Slack con workflow, nodo, error y enlace a la ejecución; reintentos con espera en los nodos de lectura	Implementado
Mensajes o envíos duplicados	Deduplicación por identificador del mensaje	Pendiente

Anexo B. Limitaciones conocidas y roadmap

Prioridad	Limitación actual	Plan de cierre
1	El Juez solo supervisa la rama Manual	Reutilizar el mismo Juez en Garantía y Mantenimiento
2	Los nodos que envían o escriben (Telegram, Slack, Google Sheets, Calendar) no se reintentan, para no duplicar mensajes, filas ni eventos	Claves de idempotencia por traceld y reintento seguro de esos nodos

Prioridad	Limitación actual	Plan de cierre
3	Sin deduplicación de mensajes repetidos	Registrar el identificador del mensaje y descartar duplicados
4	Las respuestas no citan la fuente (página del manual)	Guardar la página en los metadatos de cada fragmento y citarla en la respuesta
5	Tras un rechazo, la respuesta depende de que una persona conteste en Slack; sin respuesta, la ejecución queda en espera	Tiempo límite y aviso automático al cliente de que su consulta fue derivada
6	Cada consulta se resuelve sin memoria de la conversación	Memoria conversacional por chatId
7	Vectorización con un modelo en inglés sobre documentos en español	Migrar a un modelo multilingüe y reindexar
8	El Juez usa el mismo modelo que el agente	Evaluar con un modelo distinto para reducir el sesgo de autoevaluación
9	El Juez evalúa solo contra el contexto recuperado: si la búsqueda falla, agente y Juez coinciden en "no figura" (2 de 10 pruebas)	Segunda búsqueda independiente de verificación, embeddings multilingües y reindexación
10	El límite de longitud es una instrucción del prompt, no un control técnico (se observaron respuestas de unos 400 caracteres con un tope menor)	Nodo de validación que recorte o rechace respuestas largas antes de enviarlas
11	La ruta CORREGIR (nota 3) con reintento completo no tiene un caso limpio registrado tras el ajuste del Juez	Prueba dirigida con omisión parcial y registro del número de intento en el log
12	El audio del cliente se transcribe dos veces: al inicio del flujo y otra vez en cada rama para el registro final	Guardar el texto de la primera transcripción y reutilizarlo en el log, evitando una llamada adicional por audio


Despliegue por fases (Pre-entrega Módulo 10)

Fase	Días	Qué hace el agente	Criterio de salida
0. Modo sombra	1 a 7	Procesa consultas reales sin responder al cliente	95% de coincidencia con los mejores ejecutivos
1. Piloto de solo lectura	8 a 15	Responde consultas informativas	Menos de 1% de error sobre 300 interacciones
2. Escritura con aprobación humana	16 a 22	Propone turnos; la persona confirma	Más de 90% de aprobación sin cambios
3. Autonomía supervisada	23 a 30	Responde, verifica garantías y agenda con alertas	KPIs sostenidos


Anexo C. Repositorio y evidencias

- **Repositorio de workflows:** github.com/facucabanilla/AI-Automation-Avanzado-Trabajo-final. Contiene los 5 JSON (Manager, Worker MANUAL, Garantía, Turnos y mantenimiento y Alerta de errores) y un README con las instrucciones de importación. No incluye claves ni tokens: las credenciales figuran solo por nombre.
- **Video (opcional):** [Ver video en Loom](#). Presentación del sistema y una consulta real de garantía; dura 4 min 28 s.
- **Capturas del lienzo de n8n:** incluidas a continuación: los cinco workflows, la derivación a Slack de un rechazo y una alerta real de error.


Capturas de evidencia




Manager: recepción por Telegram, transcripción de audios, clasificación de la intención, delegación y registro final de cada interacción.




Worker MANUAL: agente con base vectorial, Juez, decisión por veredicto, autocorrección, derivación a Slack y respuesta al cliente en texto o voz.



Worker Garantía: consulta a su base vectorial y respuesta en el formato original del cliente.



Worker Turnos y mantenimiento: consultas de mantenimiento y pedido de turnos con aprobación humana en Slack y alta del evento en Google Calendar.



Workflow de alertas: se activa ante una falla de cualquier otro workflow y avisa por Slack.

⚠️ RESPUESTA RECHAZADA POR EL JUEZ ⚠️ - Usuario: [REDACTED] - Consulta Que luces lleva?Cuál es la capacidad del tanque de combustible? Cuánto sale el seguro? - Respuesta Agente: - **Luces:** La mayoría de las luces exteriores e interiores son de tecnología **LED** (luces altas, bajas, de conducción diurna, posición, frenos, - Nota: 2/5 - Motivo: El usuario realizó 3 preguntas distintas: 1) ¿Qué luces lleva?, 2) ¿Cuál es la capacidad del tanque de combustible?, y 3) ¿Cuánto sale el seguro?. El agente respondió incompletamente solo a la primera parte de las luces (y de forma cortada), omitiendo por completo la capacidad del tanque de combustible y la pregunta sobre el seguro (esta última no figura en la documentación, pero debió indicarse). Por lo tanto, responde correctamente menos de la mitad de las partes. Partes: 3 detectadas, 1 correctas.

Derivación a una persona tras un rechazo real del Juez (traceld 1688): nota 2 de 5, motivo y conteo de partes.

❌ ERROR en Asistente Ford - Worker MANUAL Nodo: Send a text message Motivo: Bad request - please check your parameters Ejecución (traceld si es el Manager): 1677 <https://fc-automation.app.n8n.cloud/workflow/UwekoYTZbDI6COsk/executions/1677>
Automated with this [n8n workflow](#)

Alerta real generada por el workflow de errores ante una falla de envío en el Worker MANUAL.